

Reporte

Autor:Nicolas Moreno Martinez

5 de julio de 2026

Índice general

1. Metodología	2
2. Introducción a los datos	5
3. resultados	7

Capítulo 1

Metodología

Con el fin de clasificar los datos mencionados en el item anterior, en esta investigación se utilizó una técnica de machine learning de aprendizaje no supervisado, técnica que busca agrupar objetos similares en conjuntos llamados clústeres, de manera que los elementos dentro de un grupo sean lo más parecidos posible entre sí y lo más diferentes posible respecto a otros grupos, similar a una partición clásica en teoría de conjuntos, para hallar dichos grupos ubicados en los datos se usaron dos algoritmos de clustering, llamados K-means y DBSCAN, ambos realizados con 3 métricas distintas, esto para comparar efectividad del mismo, (Euclidiana, DTW y MSM)

Ahora se explicará un poco el funcionamiento de estos algoritmos de clasificación, las distintas métricas y a su vez el como se implementaron en este conjunto de datos en particular, principalmente porque nosotros queremos clasificar series de tiempo y no puntos o grupos de puntos, se explicará en su forma mas general, para luego ser explicado de forma específica a nuestro contexto y posteriormente en el proximo item se exhibiran los resultados posteriores al aplicar estas clasificaciones.

K-means: Este es un algoritmo clasico de clasificación de grupos o clustering, consiste en elegir (k) número de separaciones en el conjunto, usualmente este k determinado por otras tecnicas, una vez determinado este número el algoritmo tiene como principio minimizar distancias de ese punto llamado centroide a los puntos cercanos a el, la ubicación de este centroide en el conjunto de datos es justo lo que se busca minimizar, es el objetivo de este algoritmo, al ser ubicado estos k -puntos en sus lugares más optimos los que estan a una minima de este punto y lejana de los otros serán los que conformarán cada k -cluster.

El algoritmo K-means busca minimizar la función objetivo:

$$J = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2$$

donde:

J es un escalar que representa el costo total del clustering.

k es el número de clústeres definidos.

C_j es el conjunto de puntos asignados al clúster j .

μ_j es el centroide del clúster j , un vector en este caso en $\mathbb{R}^2$.

El centroide de cada clúster se calcula como la media de sus puntos:

$$\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$$

donde $|C_j|$ es el número de puntos en el clúster j .

usando estas funciones podemos determinar clasificación de grupos.

DBSCAN: Este es un algoritmo un poco más robusto que el k-means pero a su vez, más complejo y delicado en cuanto a precisión, ya que se basa más en la densidad de el conjunto de datos que en una forma de separación, funciona definiendo un radio de vecindad usualmente llamado ϵ al igual que el k en el algoritmo anterior este epsilon es deducido a partir de otras técnicas, elegido el ϵ este será el parametro principal con el que se rigen los llamados vecindarios, estos vecindarios parten de un centro o núcleo el cual se nombra bajo una condición inicial alguien es núcleo si tiene suficientes puntos cerca de el para conformar un vecindario, por tanto el minimo de puntos va a ser una variable a tener en cuenta, esta variable usualmente se nombre tomando en cuenta la dimensionalidad de la nube de puntos más una unidad la elección de clusteres en este caso no es fija como en el k-means es teniendo en cuenta los candidatos a nucleos, es por esto que puede que este algoritmo sea más sensible a ruido de los datos y demás factores que lo hacen más complicado.

Condiciones y funciones que contiene el DBSCAN;

Sea un conjunto de datos D , un punto $p \in D$, un radio $\epsilon > 0$ y un mínimo de puntos MinPts.

La vecindad de un punto p se define como:

$$N_\epsilon(p) = \{q \in D \mid \|p - q\| \leq \epsilon\}$$

Un punto p es un punto núcleo si:

$$|N_\epsilon(p)| \geq \text{MinPts}$$

Punto borde: p no cumple la condición de núcleo, pero existe un núcleo q tal que $p \in N_\epsilon(q)$.

Punto ruido: p no es núcleo ni borde, es decir, no pertenece a ningún clúster.

Los clústeres se forman conectando puntos núcleo y sus vecinos alcanzables:

$$C = \{p \in D \mid p \text{ es alcanzable desde algún núcleo}\}$$

Una vez mencionados los algoritmos, en su forma más general se hará un pequeño ajuste para mostrar en nuestro caso como clasificaremos las series de tiempo usando precisamente estos dos métodos, entonces hablaremos de la métrica, una métrica en sí es una distancia que nos dice que tan cerca estan dos objetos entre sí, justo lo que mide el clustering por tanto ambos algoritmos los rige una métrica, esta dependerá siempre del contexto de los objetos que estemos midiendo, en el caso particular de las series de tiempo nos ajustaremos a tres métricas, las cuales nos ayudarán a hacer el proceso de medición o cercanía entre las series de tiempo, ya que si midieramos de la misma forma como medimos puntos a curvas o a matrices o a cualquier elemento de espacios diferentes, probablemente tendríamos resultados erróneos o muy alejados de lo que realmente queremos, es por eso que a los algoritmos les cambiaremos sus distancias predeterminadas, por algunas que son para series de tiempo, pero el proceso de clustering funcionará exactamente igual que si lo hicieramos con cualquier objeto, para las medir distancias entre series de tiempo manejaremos tres métricas, estas serán explicadas y posteriormente usadas para ver alguna diferencia notoria al usarla para cada algoritmo.

No sin antes mencionar el objeto con el que realmente se trabajan estos algoritmos, matrices, uno al medir series de tiempo realmente lo hace sobre matrices, estas matrices

actúan así por columna tendremos cada categoría o serie de tiempo a comparar con otras y por fila tendremos sus registros a través del tiempo.

Distancia euclidiana: La distancia euclidiana, la más sencilla de las tres distancias a mencionar, mide la distancia vertical entre cada par de puntos pa series de tiempo punto a punto y su distancia clásica euclidiana de la recta que hay entre esos puntos al final sumando esas distancias para decidir si son similares entre menor sea su distancia, cabe resaltar que es la distancia más clásica y más usada pero es muy sencillo que se sobreajuste a casi cualesquieras series de tiempo, ya que es clasificara por cercanía entre las series así su comportamiento a lo largo del tiempo no sea tan similar.

Distancia DTW: La distancia DTW mide la distancia entre dos series de tiempo de la siguiente manera, la idea es hallar patrones por muy desfazadas o diferentes que puedan ser las series a través del tiempo, lo que hace es hallar caminos en que las series se parezcan a través del tiempo, por decirlo así estirando a la otra grafica mirando todas las posibles distancias entre puntos que pueda tener una serie con respecto a la otra, luego el algoritmo tomará el camino con mejor resultados, lo que significa que se minimice la distancia, este en un principio analiza la distancia de los puntos igual que la distancia euclidiana en la primera iteración, a medida que las iteraciones suben estirará la grafica contraria y las distancias ya no serán verticales sino cada vez más diagonales, construyendo una matriz de costos la cual al final del algoritmo se minimiza quedandose con la distancia más cercana.

distancia MSM: Esta es quizá la más matemáticamente hablando, estructurada de las 3, sin embargo también la más sensible, la distancia funciona así, no se quiere comparar una serie de tiempo con la otra más bien se quiere ver si alterando con ciertos pasos a una serie tiempo, que tan costoso es convertirla en la otra serie de tiempo, muy similar a una transformación lineal, lo que busca es construir un matriz de costos, minimizando el camino, acá es donde entra lo delicado, las gráficas pueden ser muy similares, pero a la vez ser muy costosas de transformar en la otra, lo que dificulta a veces la efectividad del algoritmo, las tres herramientas con las que este algoritmo puede comparar series de tiempo son; comparar usando la distancia euclidiana, estirar a la serie 1 y estirar a la serie 2. con estirar se refiere a no seguir midiendo punto a punto sino saltarse un valor para medir con la otra serie y viceversa.

Capítulo 2

Introducción a los datos

En Colombia existe una institución que dirige exámenes nacionales de calidad educativa, en estos exámenes se mide en este caso la calidad de los colegios nacionales, tanto publicos, privados, rurales en general cualquier colegio en el país, el grado en el que se hace este examen es en 11° o comunmente al finalizar los estudios en bachillerato, el examen se realiza 2 veces al año, este examen tiene una dificultad igual o menor a lo aprendido durante todos los años del colegio, además es calificado por areas obteniendo individualmente un puntaje individual, el cual es usado comunmente como se menciona para medir la calidad de la institución donde estudia el estudiante a su vez que al mismo estudiante, obteniendo beneficios luego de cierto puntaje, por lo que sí es un examen ciertamente importante, a su vez es un requisito para ingresar a cualquier entidad de educación superior dentro del país, la entidad encargada de esto (meter referencia del icfes), llamada igual que el examen, es quien brinda los datos publicos con los que estoy trabajando, en un historico de registros semestrales,

se hará un previo resumen de como se interpretan los datos, para el analisis posterior.

Lo primero a mencionar es que se hará una clasificación departamental para hacer una clasificación de cuales departamentos son los más similares en cuanto a los resultados del examen, una vez tomado esto ahora vamos a tiempos, el examen se hace desde 1968, sin embargo la mayor cantidad de departamentos implicados con registro semestral completo, 25 departamentos, se da desde el año 2010-1 hasta el 2025-2, sin embargo no falta mucho para tener otro registro de 2026-1 , los departamentos mencionados son;

casanare, caldas, tolima, caqueta, norte de santander, cordoba, nariño, santander, cundinamarca, cesar, huila, atlantico, la guajira, cauca, bogota, arauca, boyaca, risaralda, bolivar, putumayo, magdalena, quindio, valle del cauca, antioquia, meta

este será el primer filtro de nuestros datos, datos que son convertidos a data frame por departamento y por cada semestre desde 2010-1 hasta 2025-2 menos un periodo donde el icfes sufrio un por año, es decir 31 registros de historicos de puntajes globales, luego el tema de las columnas de los datos, estos datos tienen de promedio de 85 a 90 columnas dependiendo del periodo, ya que estas varían dependiendo de el periodo en el que nos encontremos, ya que en 2014-2 se re estructuro el icfes y sus exámenes, haciendolos con diferencia más centrados y a su vez re escalandolos, escala que tendremos en cuenta al mirar los puntajes,

de 2010-1 a 2014-1, puntajes globales entre 0 a 700, 7 areas evaluativas de 100 puntos máximo cada una.

de 2014-2 a actualidad puntajes globales entre 0 a 500, 5 areas evaluativas de 100 puntos máximo cada una.

Teniendo en cuenta esto, ahora vamos a las columnas, como nosotros necesitamos pocas columnas para hacer una buena interpretación de nuestras series de tiempo como cada data set ya esta en categoria departamento, solo juntariamos todos los años en todos los departamentos, considerando nuestra primera hipótesis importante, para la columna 'puntaje global', que en el primer periodo mencionado nos toco construir sumando las columnas de las 7 areas mencionadas, como esta columna por año tiene aproximadamente entre 200.000 y 450.000 registro aproximadamente lo que se hizo fue asumir que se tendría una mejor interpretación de el puntaje global por departamento si se tomaba la mediana de todos estos datos, esto porque estadisticamente es un valor incesgado hacia valores atipicos, entonces así se reducen los registros por departamento y año-semester en unidimensionales en cuanto a filas, ahora para todas las columnas restantes lo que se hizo fue por ahora eliminarlas, quedandonos con una columna por data frame ahora si uniendo cada departamento en una estructura de diccionario por año-semester en el cual la llave es el departamento, y cada data frame tiene dos columnas año y puntaje global, el cual será nuestro primer ajuste para tenera series de tiempo, en un proximo trabajo puede ser interesante clasificar de pronto por correlación o algún tipo de algoritmo otras columnas de las eliminadas para trabajar las series de tiempo en más dimensiones, una vez hecho esto no se ha realizado ningun tratamiento a la columna puntaje global para la escala entre periodos mencionada, por el hecho de que no se logro afinidad o alguna mejora en cuanto a visualización de las series de tiempo.

Capítulo 3

resultados

Una vez descritos los datos y explicando conceptos utilizados para el clustering se enlistarán todos los resultados obtenidos al procesar los datos por clustering y por métrica cada algoritmo, explicando por su puesto su interpretación, tanto por contexto como por algoritmo, evidenciando diferencias, efectividad y errores, comparando y explicando en este caso cual sería la mejor algoritmo junto con la mejor métrica para clasificar series de tiempo en nuestro conjunto de datos en particular.

- DBSCAN (euclidian):

- DBSCAN (DTW)

- DBSCAN (MSM)

- K-means (euclidian)

- K-means (DTW)

- K-means (MSM)