

- Metodología

Con el fin de clasificar los datos mencionados en el item anterior, en esta investigación se utilizó una técnica de machine learning de aprendizaje no supervisado, técnica que busca agrupar objetos similares en conjuntos llamados clústeres, de manera que los elementos dentro de un grupo sean lo más parecidos posible entre sí y lo más diferentes posible respecto a otros grupos, similar a una partición clásica en teoría de conjuntos, para hallar dichos grupos ubicados en los datos se usaron dos algoritmos de clustering, llamados K-means y DBSCAN, ambos realizados con 3 métricas distintas, esto para comparar efectividad del mismo, (Euclidiana, DTW y MSM)

Ahora se explicará un poco el funcionamiento de estos algoritmos de clasificación, las distintas métricas y a su vez el como se implementaron en este conjunto de datos en particular y posteriormente en el proximo item los resultados posteriores a aplicar estas clasificaciones.

K-means: Este es un algoritmo clásico de clasificación de grupos o clustering, consiste en elegir (k) número de separaciones en el conjunto, una vez determinado este número el algoritmo tiene como principio minimizar distancias de ese punto llamado centroide a los puntos cercanos a él, la ubicación de este centroide en el conjunto de datos es justo lo que se busca minimiza es el objetivo de este algoritmo, al ser ubicado estos k -puntos en sus lugares más óptimos los que están a una distancia similar de este punto son los que cumplen la distancia mínima también y serán los que conformarán el cluster de cada k .

El algoritmo K-means busca minimizar la **función objetivo**:

$$J = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2$$

donde:

J es un **escalar** que representa el costo total (inercia) del clustering.

k es el número de clústeres definidos.

C_j es el conjunto de puntos asignados al clúster j .

μ_j es el **centroide** del clúster j , un vector en $\mathbb{R}^n$.

El centroide de cada clúster se calcula como la media de sus puntos:

$$\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$$

donde $|C_j|$ es el número de puntos en el clúster j .

- datos

En Colombia existe una institución que dirige exámenes nacionales de calidad educativa, en estos exámenes se mide en este caso la calidad de los colegios nacionales, tanto públicos, privados, rurales en general cualquier colegio en el país, el grado en el que se hace este examen es en 11° o comunmente al finalizar los estudios en bachillerato, el examen se realiza 2 veces al año, este examen tiene una dificultad igual o menor a lo aprendido durante todos los años del colegio, además es calificado por áreas obteniendo individualmente un puntaje individual, el cual es usado comunmente como se menciona para medir la calidad de la institución donde estudia el estudiante a su vez que al mismo estudiante, obteniendo beneficios luego de cierto puntaje, por lo que sí es un examen ciertamente importante, a su vez es un requisito para ingresar a cualquier entidad de educación superior dentro del país, la entidad encargada de esto (meter referencia del icfes), llamada igual que el examen, es quien brinda los datos públicos con los que estoy trabajando, en un historico de registros semestrales,

se hará un previo resumen de como se interpretan los datos, para el analisis posterior.

Lo primero a mencionar es que se hará una clasificación departamental para hacer una clasificación de cuales departamentos son los más similares en cuanto a los resultados del examen, una vez tomado esto ahora vamos a tiempos, el examen se hace desde 1968, sin embargo la mayor cantidad de departamentos implicados con registro semestral completo, 25 departamentos, se da desde el año 2010-1 hasta el 2025-2, sin embargo no falta mucho para tener otro registro de 2026-1 , los departamentos mencionados son;

casanare, caldas, tolima, caqueta, norte de santander, cordoba, nariño, santander, cundinamarca, cesar, huila, atlantico, la guajira, cauca, bogota, arauca, boyaca, risaralda, bolivar, putumayo, magdalena, quindio, valle del cauca, antioquia, meta

este será el primer filtro de nuestros datos, datos que son convertidos a data frame por departamento y por cada semestre desde 2010-1 hasta 2025-2 menos un periodo donde el icfes sufrio un por año, es decir

- resultados
 - DBSCAN (euclidian)
 - DBSCAN (DTW)
 - DBSCAN (MSM)
 - K-means (euclidian)
 - K-means (DTW)
 - K-means (MSM)